

Projet STATIS

Feuille de route

Introduction

On se propose d'étendre l'ACP à l'analyse factorielle d'un multi-tableau.

Il existe plusieurs façons de le faire, STATIS en est une.

Il existe aussi plusieurs types de multi-tableaux. Nous en distinguerons deux:

Tableau à trois entrées (situation 1)

Il s'agit d'un tableau à trois indices, par exemple un tableau décrivant n individus à l'aide de p variables à T dates. Les indices courants seront notés $1 \leq i \leq n$, $1 \leq j \leq p$ et $1 \leq t \leq T$.




Figure 1. Tableau à trois entrées

Un tel tableau peut être décomposé en T tableaux juxtaposés de dimensions *identiques* (n, p) . Cette identité de dimensions entre les T tableaux homologues permet une extension de l'ACP dans laquelle on considère chaque tableau comme une "variable" décrivant $n \times p$ "individus" (i, j) .

Nous formaliserons d'abord cette extension de l'ACP, appelée STATIS1.

Tableau avec partition thématique (situation 2).




Figure 2. Tableau à partitionnement thématique

Un tel tableau est constitué de q tableaux décrivant les n individus à l'aide de groupes de variables différents, chaque groupe appartenant conceptuellement à un thème précis. Chacun de ces tableaux $X_m, 1 \leq m \leq q$ possède p_m variables (colonnes).

Le fait que ces tableaux ne possèdent qu'une dimension commune, celle des individus, ne permet pas d'utiliser directement STATIS1. Nous devons donc adapter cette dernière à la situation 2.

I - Situation 1

1. Préliminaires

0. Cherchez (ou fabriquez) un tableau à trois entrées décrivant n individus avec p variables numériques à T dates. N.B. Il doit s'en trouver sur le site de l'INSEE, mais ce n'est pas forcément la meilleure source; j'en ai demandé à une autre source, au cas où.

Vous pourrez centrer-réduire les colonnes de vos tableaux si ce sont des indicateurs numériques, mais ce n'est qu'une option parmi d'autres, parce qu'en définitive, plusieurs pré-traitements seront possibles selon la nature du tableau comme de la variante de STATIS envisagée.

1.1. Produit scalaire

La matrice diagonale des poids des n individus est W (par défaut, $W = \frac{1}{n} I_n$).

On considérera également une matrice diagonale des poids des p colonnes : $C = \frac{1}{p} I_p$ par défaut.

1. Le produit scalaire entre deux matrices A et B de taille (n, p) est :

$$[A|B] = \text{tr}(CA'WB)$$

La norme d'une matrice A correspondant à ce produit scalaire sera notée $\|A\|$.

a) Écrivez ce produit scalaire sous forme $\text{tr}(\tilde{A}'\tilde{B})$ (produit scalaire de Frobénius) en

explicitant la transformation $Z \rightarrow \tilde{Z}, \forall Z(n, p)$.

- b) Montrez qu'il s'agit bien d'un produit scalaire.
- c) Explicitiez ce produit scalaire sous forme de double somme.
- d) Programmez ce produit scalaire en R, ainsi que la norme d'une matrice.

1.2. Coefficient RV

2. On définit le coefficient RV d'Escoufier entre deux matrices A et B de taille (n, p) par :

$$R(A, B) = \frac{[A|B]}{\|A\| \|B\|}$$

- a) Interprétez RV en termes géométriques.
- b) Programmez RV en R, ainsi qu'une fonction donnant la matrice Γ des coefficients RV entre T tableaux $X_t(n, p)$.

2. Programme de STATIS1

2.1. Programme

- a) Interprétez en termes d'inertie le programme suivant :

$$\max_{\|u\|^2=1} \left\| \sum_{t=1}^T u_t \frac{X_t}{\|X_t\|} \right\|^2$$

- b) Résolvez le programme.
- c) Écrivez le programme R fournissant les vecteurs u solutions des équations du premier ordre. Montrez que ces vecteurs u forment une base I -orthonormée.

2.2. Équivalence avec l'ACP d'un tableau juxtaposé "dépliant" le tableau cubique

- a) Montrez que les vecteurs u obtenus sont les vecteurs propres unitaires de l'ACP d'un tableau dont les X_t sont les "variables", et dont on précisera les "individus" ainsi que leurs poids.

- b) En déduire que les composantes principales F^1, \dots, F^k, \dots sont orthogonales au sens du produit scalaire convenable.

- c) Donnez la formule des composantes principales correspondant aux vecteurs u .

Programmez la fonction calculant la $k^{\text{ième}}$ composante F^k ainsi que la composante normée f^k correspondante.

Programmez la fonction donnant la représentation graphique des individus en plan principal (k, l) .

- d) Calculez le cosinus entre X_t et F^k .

Programmez la fonction donnant la représentation graphique des tableaux en plan principal (k, l) .

2.3. Quelles ACP d'autres "dépliages" du tableau cubique ?

- a) Quels sont les autres dépliages possibles du tableau cubique initial?
 - b) Quelle(s) ACP des tableaux dépliés pouvez-vous envisager? Pour chacune: quels sont ses "individus" et ses "variables"? Quel centrage paraît opportun? Quelle réduction? Quels éléments sont utiles à projeter en supplémentaire?
 - c) Quels sont les avantages et les inconvénients de chaque ACP d'un tableau "déplié"?
- Finalement, le "dépliage" opéré par STATIS1 était-il le plus opportun?

II - Situation 2